LAPORAN PENGEMBANGAN *DATASET* DAN PEMODELAN *MULTILABEL TEXT CLASSIFICATION & NAMED ENTITY RECOGNITION*

Disusun Oleh:

Edward Christian I.T (240712822)

Samuel Viva Gracia (240712828)

Rhiquelshen Charolim (240712846)

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNOLOGI INDUSTRI

UNIVERSITAS ATMA JAYA YOGYAKARTA

TAHUN AKADEMIK 2026/2027

DAFTAR ISI

DAFTAR ISI ii

DAFTAR GAMBAR iv

DAFTAR TABEL v

BAB I PENDAHULUAN 1

1.1 Latar Belakang 1

BAB II METODOLOGI PENELITIAN 2

2.1 Gambaran Umum Alur Penelitian 2

2.2 *Data Cleaning* dan Normalisasi Teks 2

2.2.1 Pemeriksaan Kualitas Awal dan Pembersihan *Noise* 2

2.2.2 Audit Kamus dan Normalisasi Teks Terkontrol 4

2.3 Seleksi Domain Korpus dan *Sampling* 5

2.3.1 Seleksi Batas Utas Domain 5

2.3.2 Pilot & Sampel Utama 5

2.4 Perancangan Taksonomi Label Multilabel dan Skema NER 6

2.4.1 Skema A: Taksonomi *Multilabel Text Classification* 6

2.4.2 Skema B: Taksonomi *Named Entity Recognition* (NER) dan Konversi Tag BIO 7

2.5 Proses Anotasi, Uji Coba (*Pilot*), dan Adjudikasi 8

2.5.1 Tahap Uji Coba (*Pilot Annotation*) dan Pembekuan Pedoman (*Guideline Freeze*) 8

2.5.2 Anotasi Mandiri Skala Penuh dan Penggabungan Ekspor Berbasis *Timestamp* 9

2.5.3 Adjudikasi Otomatis dan Manual 9

2.6 Metode Evaluasi Inter-Annotator Agreement (IAA) 10

2.6.1 Desain overlap annotation 10

2.6.2 Agreement pada klasifikasi multilabel 10

2.6.3 Agreement pada NER 12

2.6.4 Interpretasi dan validasi perhitungan 12

2.7 Metode *Exploratory Data Analysis* (EDA) pada *Gold Dataset* 13

2.7.1 Persiapan data 13

2.7.2 Analisis multilabel 13

2.7.3 Analisis NER 15
2.7.4 Prinsip visualisasi dan penarikan kesimpulan 15
BAB III HASIL DAN PEMBAHASAN 17
3.1 Hasil *Data Understanding* 17
3.1.1 Sumber dan Tujuan Awal Dataset 17
3.1.2 Bahasa serta Domain Data 17
3.1.3 Jumlah Data dan Struktur Kolom 18
3.1.4 Label Asli 18
3.1.5 Distribusi Awal Data 18
3.1.6 Masalah Kualitas Data yang Ditemukan 18
3.1.7 Potensi Pengembangan Dataset Menjadi Permasalahan Multilabel dan NER 19
3.2 Hasil Fase Cleaning dan Normalisasi 19
3.2.1 Hasil Pembersihan *Noise* 19
3.2.2 Hasil Audit Kamus dan Normalisasi 20
3.2.3 Hasil Seleksi Domain dan *Sampling* 21
3.3 Hasil Anotasi, *Inter Annotator Agreement* dan Adjudikasi 21
3.3.1 Hasil Uji Coba Pilot dan Revisi Pedoman 21
3.3.2 Kelengkapan Anotasi Utama 22
3.3.3 Hasil IAA Klasifikasi Multilabel 23
3.3.4 Hasil IAA NER 23
3.3.5 Contoh Disagreement 24
3.3.6 Hasil Adjudikasi 24
3.3.7 Perubahan Pedoman 25
3.4 Hasil *Exploratory Data Analysis* (EDA) 25
3.4.1 Hasil EDA *Multilabel* 25
3.4.2 Hasil EDA NER 28
3.4.3 Kesimpulan hasil EDA 31
BAB IV KESIMPULAN 32
DAFTAR PUSTAKA 33

DAFTAR GAMBAR

Gambar 3.1 Distribusi Panjang Teks 25
Gambar 3.2 Distribusi Label 26
Gambar 3.3 Jumlah Label per Teks 26
Gambar 3.4 Co-occurrence Label 27
Gambar 3.5 Korelasi Antar Label 27
Gambar 3.6 Panjang Teks per Label, Imbalance Ratio per Label, dan Kombinasi Label 28
Gambar 3.7 Distribusi Jumlah Token per Teks 28
Gambar 3.8 Jumlah Entitas per Jenis 29
Gambar 3.9 Jumlah Entitas per Teks 29
Gambar 3.10 Panjang Entitas per Jenis 30
Gambar 3.11 Entitas dengan Frekuensi Kemunculan Tertinggi per Jenis 30
Gambar 3.12 Distribusi Tag BIO per Token 31

DAFTAR TABEL

Tabel 2.1 Taksonomi dan Aturan Pelabelan Multilabel Text Classification 6
Tabel 2.2 Skala Interpretasi Nilai Kappa 12
Tabel 3.1 Ringkasan Langkah Pembersihan 20
Tabel 3.2 Ringkasan Jenis Normalisasi..... 21
Tabel 3.3 Komposisi Sampel 21
Tabel 3.4 Fleiss' Kappa per Label (1.000 teks × 3 annotator) 23
Tabel 3.5 Contoh Disagreement..... 24
Tabel 3.6 Status Keputusan Adjudikasi Label dan NER..... 24

BAB I
PENDAHULUAN

1.1 Latar Belakang

Kolom komentar pada portal berita daring di Indonesia kerap menjadi ruang diskusi yang rentan dipenuhi serangan verbal agresif, seperti yang terjadi pada polemik publik antara Komisi Perlindungan Anak Indonesia (KPAI) dan PB Djarum pada tahun 2019. Tantangan dalam mendeteksi ujaran kasar berbahasa Indonesia pada ranah ini sebelumnya telah dieksplorasi oleh Desrul dan Romadhony [1] melalui dataset "Abusive Language Detection on Indonesian Online News Comments" yang kini terintegrasi di dalam repositori terbuka NusaCrowd [2]. Namun, skema pelabelan asli pada dataset tersebut masih menggunakan pendekatan kelas tunggal (*single-label*) untuk sekadar mengukur tingkat keparahan ujaran secara umum [1]. Padahal, penelitian Ibrohim dan Budi [3] di ranah media sosial menunjukkan bahwa teks ujaran kebencian di dunia nyata sering memuat berbagai dimensi bahasa kasar sekaligus. Dalam konteks polemik KPAI dan PB Djarum, sebuah komentar di dalam dataset terbukti dapat melontarkan makian, menyisipkan ironi, menuduh motif tersembunyi, hingga menghasut pembaca secara bersamaan, sekaligus menyebutkan berbagai pihak yang berbeda sebagai sasarannya (seperti lembaga negara, organisasi non-pemerintah, atau kelompok warga). Keterbatasan label tunggal ini membuat sistem NLP gagal membedakan secara spesifik bentuk jenis serangan dan siapa pihak yang sesungguhnya menjadi target utamanya.

Untuk mengatasi keterbatasan tersebut, proyek ini mereformulasi korpus komentar berita menjadi dua permasalahan NLP yang saling melengkapi, yaitu *Multilabel Text Classification* pada tingkat dokumen dan *Named Entity Recognition* (NER) pada tingkat rentang token (*span*). Skema multilabel dirancang untuk mendeteksi lima dimensi serangan verbal secara simultan, yakni *INSULTING*, *MOCKING*, *ACCUSING*, *PROVOKING*, dan *CURSING*. Sementara skema NER berbasis tag BIO digunakan untuk mengekstraksi tipe entitas pihak yang disebut, meliputi *GOV_ORG*, *NONGOV_ORG*, *PERSON*, dan *GROUP*. Mengingat variasi subjektivitas dan pemahaman manusia dalam pelabelan teks dapat memengaruhi kualitas pemodelan dan evaluasi secara signifikan [4] tahap Ujian Tengah Semester (UTS) dalam proyek ini difokuskan sepenuhnya pada pembangunan *gold standard dataset* yang tervalidasi secara metodologis. Sebanyak 1.000 sampel teks dianotasi secara mandiri oleh tiga *annotator* berdasarkan pedoman anotasi yang ketat, yang dilanjutkan dengan evaluasi *Inter-Annotator Agreement* dan penyelesaian konflik melalui proses *adjudication* guna menghasilkan dataset berkualitas sebagai fondasi untuk EDA.

BAB II
METODOLOGI PENELITIAN

2.1 Gambaran Umum Alur Penelitian

Pengembangan *gold standard dataset* pada penelitian ini dirancang sebagai satu *pipeline* rekayasa data Pemrosesan Bahasa Alami (*Natural Language Processing* / NLP) yang sekuensial, dapat dilacak (*traceable*), dan dapat direproduksi (*reproducible*). Secara garis besar, tahapan metodologi dibagi menjadi enam fase utama: 1. pembersihan *noise* teknis dan normalisasi leksikal terkontrol pada korpus mentah, 2. seleksi korpus spesifik domain polemik KPAI vs PB Djarum, 3. pengambilan sampel terstratifikasi (*stratified sampling*) untuk data uji coba (*pilot*) dan data anotasi utama, 4. perancangan taksonomi *Multilabel Text Classification* dan *Named Entity Recognition* (NER) beserta penyusunan pedoman anotasi (*annotation guideline*), 5. pelaksanaan anotasi mandiri oleh tiga *annotator*, evaluasi kesepakatan antar-*annotator* (*Inter-Annotator Agreement* / IAA), serta resolusi konflik melalui *adjudication*, dan 6. *Exploratory Data Analysis* (EDA) pada *gold dataset* final untuk memetakan kelayakan distribusi serta tingkat ketidakseimbangan kelas (*imbalance*) sebelum tahap pemodelan.

2.2 *Data Cleaning* dan Normalisasi Teks

2.2.1 Pemeriksaan Kualitas Awal dan Pembersihan *Noise*

Sebelum pemrosesan dilakukan, setiap baris data diberi penanda identitas permanen (ANC-0001 dan seterusnya sesuai urutan indeks asli) agar perubahan pada setiap rekaman dapat dilacak lintas tahapan. Pemeriksaan kualitas awal dilakukan terhadap kriteria minimum yang meliputi nilai kosong (*missing values*), teks tanpa karakter alfabet (*empty/non-letter text*), duplikasi teks, kerusakan *encoding* karakter (*mojibake* dan *escape sequence*), sisa *markup* HTML/URL/sebutan akun, ketidakteraturan spasi, serta komentar yang sangat pendek.

Prinsip utama dalam tahapan *data cleaning* pada penelitian ini adalah memisahkan perbaikan *noise* akibat proses *web crawling* dari gaya penulisan asli komentator. Teks asli disimpan tanpa perubahan pada kolom text_raw, sedangkan hasil pembersihan disimpan pada kolom text_clean yang selanjutnya dibekukan sebagai teks acuan anotasi. Pembersihan dieksekusi secara berurutan melalui delapan fungsi tingkat karakter/teks dan aturan penyaringan baris.

1. Pemulihan *Mojibake*

   Mengembalikan byte UTF-8 yang salah terbaca sebagai *encoding* Mac Roman saat

crawling ke karakter Unicode aslinya.

2. Dekode *Escape Sequence*

   Mengonversi pola *escape* heksadesimal bergaya JavaScript (%uXXXX termasuk pasangan *surrogate* UTF-16) kembali menjadi karakter atau emoji asli.

3. Penanganan Karakter Hilang

   Menghapus karakter pengganti Unicode (U+FFFD / ``) yang rusak sejak awal atau menggantinya dengan satu spasi apabila berada di tengah kata guna mencegah penggabungan dua token yang berbeda.

4. Penghapusan Karakter Tak Terlihat

   Menghapus *zero-width space*, *invisible separator*, dan *Byte Order Mark* (U+200B–U+200F, U+2060–U+2064, U+FEFF) yang tidak tampak secara visual tetapi dapat menggeser perhitungan indeks *offset* karakter pada tugas NER.

5. Standardisasi Unicode NFC

   Menyeragamkan representasi kombinasi karakter ke dalam *Normalization Form Canonical Composition* (NFC).

6. Pembersihan *Markup* dan *Escape* JSON

   Menghapus tag HTML, mengembalikan *HTML entities* (seperti &) ke karakter aslinya, serta mengubah *escaped slash* (\/) menjadi / .

7. Penyensoran Tautan dan Nama Akun

   Mengganti tautan web dengan *placeholder* [URL] dan penyebutan akun (@username) dengan [USER] demi menjaga privasi serta stabilitas posisi token dengan pengecualian untuk token kata yang teridentifikasi sebagai bagian dari daftar slogan tagar di korpus (seperti BubarkanKPAI).

8. Normalisasi Spasi dan Pemisahan Tanda Baca

   Menyeragamkan baris baru (\n), tab, dan spasi berlebih menjadi satu spasi tunggal, dilanjutkan dengan menyisipkan satu spasi setelah tanda baca (.,!?;:) yang terjepit tepat di antara dua karakter huruf alfabet (misalnya PB.Djarum menjadi PB. Djarum). Langkah ini dirancang khusus agar *tokenizer* berbasis spasi pada perangkat anotasi tidak menggabungkan kata sebelum dan sesudah tanda baca menjadi satu token tunggal yang menghalangi penyorotan entitas NER, tanpa merusak format angka desimal atau ribuan.

9. Eliminasi Baris Tidak Layak

   Membuang baris yang sama sekali tidak mengandung huruf alfabet setelah dibersihkan serta menghapus baris duplikat berdasarkan pencocokan text_clean secara *case-insensitive* dengan mempertahankan kemunculan pertama. Komentar yang sangat

pendek (1–3 kata) tetap dipertahankan selama mengandung huruf alfabet, karena dalam domain komentar berita, ujaran singkat kerap memuat makian langsung atau tagar hasutan yang menjadi target utama klasifikasi.

2.2.2 Audit Kamus dan Normalisasi Teks Terkontrol

Mengingat teks komentar daring Indonesia memiliki variasi ejaan tidak baku (*slang*, singkatan, dan salah ketik) yang sangat tinggi, proses normalisasi leksikal tetap diperlukan untuk keperluan analisis kosakata pada tahap EDA dan ekstraksi fitur pemodelan. Supaya tidak merusak *offset* karakter pada span NER yang mengacu pada text_clean, hasil normalisasi disimpan ke dalam kolom terpisah bernama text_norm.

Tahap normalisasi diawali dengan penyusunan daftar proteksi yang mencakup lima kelompok token yang dilarang diubah: 1. kata nama pihak/entitas (GOV_ORG, NONGOV_ORG, PERSON), 2. frasa multi-kata nama institusi atau pelesetan spesifik domain (seperti komisi perlindungan anak indonesia, pb djarum, dan k pea i), 3. tagar dan sebutan akun, 4. *placeholder* [URL] dan [USER], dan 5. token kata kasar yang disensor dengan simbol atau angka (b*rak, beg0). Selanjutnya, dilakukan audit berlapis terhadap dua kamus singkatan bawaan repositori dataset asli (Acronym Words and Typos.xlsx dan kumpulan_singkatan_dan_kata_dasar.xls) melalui langkah-langkah berikut:

1. Penyaringan Otomatis

   Menghapus entri kamus yang bernilai kosong, bukan kata alfabet tunggal, identik antara bentuk asal dan baku, atau beririsan dengan daftar proteksi entitas.

2. Audit Manual dan Resolusi Konflik

   Membuang entri kamus bawaan yang maknanya melenceng di dalam konteks domain korpus (seperti singkatan lembaga dpr yang dipetakan menjadi dapur, pt menjadi patungan, atau pp menjadi pulang pergi), memperbaiki entri yang memiliki pemetaan ganda bertentangan, serta menambahkan kosakata *slang* berfrekuensi tinggi yang belum tercakup di kamus bawaan.

3. Pelurusan Rantai Transitif

   Meneruskan pemetaan berantai hingga mencapai bentuk baku akhir (misalnya ajaa → aja → saja).

Fungsi normalisasi kemudian memindai teks berhuruf kecil dari kiri ke kanan di luar rentang frasa yang diproteksi dengan urutan aturan: 1. melewati kata yang diproteksi, 2. menguraikan reduplikasi berangka (seperti anak2 menjadi anak-anak setelah kata dasarnya dinormalisasi), 3. melewati token campuran simbol/angka, 4. menyeragamkan variasi ekspresi tawa (wkwkwk → wkwk, hahahaha → haha), 5. mencocokkan kata pada kamus

normalisasi final, dan 6. mereduksi deretan huruf berulang dengan memilih kandidat kombinasi 1 atau 2 huruf yang memiliki frekuensi tertinggi di korpus sebelum dicocokkan kembali ke kamus.

2.3 Seleksi Domain Korpus dan *Sampling*

2.3.1 Seleksi Batas Utas Domain

Korpus id_abusive_news_comment menghimpun komentar dari berbagai topik berita nasional tahun 2019 yang tersusun secara berurutan per artikel berita. Penelitian ini membatasi domain hanya pada tiga utas berita yang membahas polemik penghentian Audisi Umum Beasiswa Bulu Tangkis PB Djarum akibat teguran KPAI.

2.3.2 Pilot & Sampel Utama

Sebelum pengambilan sampel dilakukan pada populasi komentar domain, diterapkan penyaringan hampir-duplikat (*near-duplicate filtering*) dengan mengabaikan seluruh tanda baca, spasi, angka, kapitalisasi, dan simbol tagar. Dari setiap kelompok teks yang memiliki rangkaian huruf identik (misalnya variasi #BUBARKAN KPAI, bubar kan KPAI !!!!, dan #bubarkankpai), hanya disimpan maksimal satu varian bertagar dan satu varian tanpa tagar, sementara sisanya dikeluarkan dari kerangka populasi *sampling*. Langkah ini bertujuan mencegah pembengkakan frekuensi label akibat komentar *spam* seragam sekaligus menghindari *data leakage* antar-*split* pada tahap pelatihan model di UAS.

Mengingat distribusi komentar abusif pada data alami umumnya timpang (*skewed*) ke arah komentar netral, pengambilan sampel acak murni (*simple random sampling*) berisiko membuat jenis serangan verbal yang spesifik atau langka tidak memiliki cukup contoh untuk dilatih. Oleh karena itu, diterapkan metode pengambilan sampel terstratifikasi dua lapis dengan nilai pengacak tetap (SEED = 42):

1. Pembentukan Strata Setiap teks dalam populasi domain dipindai menggunakan ekspresi reguler (*regex*) kata kunci indikasi untuk kelima dimensi serangan verbal serta diperiksa label keabusifan aslinya. Teks yang memiliki minimal satu kecocokan pola kata kunci atau berlabel asli abusif (orig_label > 1) dimasukkan ke dalam strata prioritas, sedangkan teks lainnya dimasukkan ke dalam strata umum.
2. Pengambilan Sampel *Pilot* (N = 50)

   Sampel *pilot* digunakan khusus untuk menguji keterbacaan pedoman dan kalibrasi *annotator*, serta tidak dimasukkan ke dalam *gold dataset*.
3. Pengambilan Sampel Utama (N = 1000)

   Seluruh teks yang tersisa pada strata prioritas diambil secara penuh, kemudian kekurangan kuota pada masing-masing utas berita dipenuhi secara acak dari strata

umum.

2.4 Perancangan Taksonomi Label Multilabel dan Skema NER

2.4.1 Skema A: Taksonomi *Multilabel Text Classification*

Reformulasi label tingkat dokumen dirancang untuk mengubah pelabelan tunggal keabusifan menjadi lima label serangan verbal spesifik yang dapat muncul secara bersamaan (*multilabel*), ditambah dua label status eksklusif (NONE dan UNANNOTATABLE).

Tabel 2.1 Taksonomi dan Aturan Pelabelan Multilabel Text Classification

Label	Definisi	Aturan
INSULTING	Merendahkan sifat, martabat, kecerdasan, atau kegunaan diri target secara langsung maupun lewat ungkapan baku.	Makian kasar/tersensor, sebutan merendahkan, sifat buruk, ungkapan baku (kacamata kuda), pertanyaan retoris nirguna. Tidak termasuk: kritik terhadap keputusan/aturan (salah sasaran), kata kasar sebagai seruan tanpa target.
ACCUSING	Menyatakan atau menyiratkan bahwa target melakukan perbuatan tercela, memiliki niat/motif buruk, berpihak tersembunyi, lalai/pilih kasih, atau lari dari tanggung jawab.	Tuduhan motif dana/panggung/pencitraan, afiliasi terselubung, makan gaji buta, pengabaian kasus konkret, cuci tangan. Tidak termasuk: melaporkan tuduhan pihak lain, kritik keputusan keliru tanpa motif jahat, saran prioritas yang sopan.
PROVOKING	Mengajak, menuntut, atau mendukung tindakan penghukuman, penyingkiran, pembubaran, atau permusuhan terhadap target.	Kata kerja tindakan (bubarkan, tutup, pecat, mundur, boikot), tagar slogan ajakan (#BubarkanKPAI), tuntutan bersyarat. Tidak termasuk: tuntutan akuntabilitas normatif (evaluasi, klarifikasi, minta maaf).
CURSING	Mendoakan, mengharapkan, atau menyoraki kemalangan/nasib buruk yang menimpa target tanpa	Harapan buruk (semoga tenggelam/celaka), sorakan kemalangan (mampus, rasain,

Label	Definisi	Aturan
	meminta pihak tertentu bertindak.	biar nyahok), klaim pantas celaka tanpa pelaku. Tidak termasuk: harapan tindakan oleh pelaku tertentu (semoga dicopot → PROVOKING), prediksi buruk non-target.
MOCKING	Membuat target tampak konyol atau dipermalukan lewat cara tidak harfiah: ironi, sarkasme, pujian/ucapan selamat palsu, tawa ejekan, pelesetan nama, tantangan pengganti, atau analogi absurd.	Pujian/terima kasih palsu, tawa/emoji yang menertawakan target, pelesetan (K pea I, bulubebek), tantangan sinis (KPAI saja yang sponsori), parodi survei. Tidak termasuk: pujian tulus disertai argumen, ungkapan baku (otak udang → INSULTING saja), usulan kerja sama serius.
NONE	Komentar dapat dipahami tetapi tidak memuat satu pun dari lima jenis serangan verbal di atas.	Mencakup kritik objektif terhadap kebijakan/keputusan, saran, pembelaan, pertanyaan penjelasan, atau tuntutan evaluasi biasa. Tidak boleh digabung dengan label lain.
UNANNOTATABLE	Teks tidak bermakna, hampir seluruhnya berbahasa daerah/asing tanpa konteks, atau tidak dapat dinilai tanpa melihat komentar lain.	Berdiri sendiri, tetap diikutsertakan dalam perhitungan IAA untuk menguji konsistensi *annotator*, tetapi dikeluarkan dari *gold dataset* final.

2.4.2 Skema B: Taksonomi *Named Entity Recognition* (NER) dan Konversi Tag BIO

Dirancang skema NER berbasis rentang token (*span*) yang terdiri atas empat tipe entitas:

1. **GOV_ORG** (Organisasi Pemerintah)

   Lembaga negara, kementerian, komisi negara, sebutan eksplisit [pemerintah], serta Badan Usaha Milik Negara (BUMN), seperti [KPAI], [Komisi Perlindungan Anak

Indonesia], [kemenpora], [Komnas HAM], dan [Pertamina]. Sebutan wilayah atau konsep geopolitik (Indonesia, NKRI, negara, bangsa) tidak disorot.

2. **NONGOV_ORG** (Organisasi Non-Pemerintah)

   Organisasi swasta, perusahaan, merek dagang, yayasan, klub olahraga, federasi, partai, maupun Lembaga Swadaya Masyarakat (LSM) yang disebut namanya secara spesifik, seperti [PB Djarum], [Djarum Foundation], [lentera anak], [Komnas PA], dan [Wismilak]. Kata benda organisasi generik tanpa nama (lembaga, komisi, perusahaan rokok, sponsor) tidak disorot.

3. **PERSON** (Individu)

   Nama orang tertentu beserta kata sapaan yang menempel langsung di depannya, seperti [Susanto], [Kevin Sanjaya], [Pak Jokowi], dan [pak de jokowi]. Kata ganti (dia, mereka), sapaan tanpa nama (bu, pak), jabatan struktural tanpa nama diri (ketua, komisioner, menteri, presiden), tokoh fiksi, serta julukan ejekan tidak disorot.

4. **GROUP** (Kelompok Manusia)

   Sebutan umum untuk kategori atau sekumpulan manusia yang memenuhi tiga syarat:

   a. menunjuk manusia (bukan kiasan seperti bibit)
   b. menunjuk kategori kolektif (bukan merujuk satu individu tertentu)
   c. bukan nama organisasi, jabatan anggota organisasi, ataupun kata ganti (kita, kami, orang, manusia).

   Untuk menjaga konsistensi *span boundary*, tipe GROUP hanya menyorot kata inti seperti [anak2], [atlet], [rakyat], [netizen], [perokok], [peserta], dan [generasi]. Pengecualian untuk frasa [orang tua] yang selalu disorot utuh dua kata.

2.5 Proses Anotasi, Uji Coba (*Pilot*), dan Adjudikasi

2.5.1 Tahap Uji Coba (*Pilot Annotation*) dan Pembekuan Pedoman (*Guideline Freeze*)

Mengikuti siklus rekayasa anotasi standar *Model-Annotate-Model-Annotate* (MAMA), proses pelabelan diawali dengan fase uji coba (*pilot annotation*) pada 50 teks sampel *pilot* oleh ketiga *annotator* secara independen. Hasil kesepakatan awal pada fase *pilot* dievaluasi untuk mengidentifikasi sumber ketidaksepakatan sistematis, seperti batas antara tuduhan (ACCUSING) dan kritik kebijakan (NONE), pemisahan dimensi isi dan cara (MOCKING), serta aturan batas kata inti pada entitas GROUP. Hasil diskusi digunakan untuk menyempurnakan definisi operasional, merumuskan lima pertanyaan uji, dan membekukan pedoman anotasi (*guideline freeze* versi 1.0) sebelum anotasi utama dimulai, serta mengganti seluruh contoh di dalam pedoman dengan teks di luar sampel utama agar tidak membocorkan kunci jawaban.

2.5.2 Anotasi Mandiri Skala Penuh dan Penggabungan Ekspor Berbasis *Timestamp*

Anotasi utama terhadap 1.000 teks sampel dilaksanakan menggunakan antarmuka berbasis web Prodigy [5]. Berkas masukan Prodigy (.jsonl) dirancang secara *blind* hanya memuat id, text (text_clean), dan metadata judul berita asal tanpa menyertakan label asli dataset, kolom text_norm, maupun penanda strata indikasi. Ketiga *annotator* menganotasi keseluruhan 1.000 teks yang sama secara penuh (*100% overlap*) dan mandiri.

Untuk menjamin integritas data selama proses ekspor bertahap dari peladen Prodigy, diterapkan algoritma penggabungan inkremental berbasis kunci komposit (id, _annotator_id). Apabila sebuah pasangan teks dan *annotator* muncul di lebih dari satu berkas ekspor, sistem secara otomatis mempertahankan rekaman dengan atribut waktu (_timestamp) paling mutakhir dan memverifikasi bahwa tidak ada satu pun baris anotasi terdahulu yang hilang. Sebelum perhitungan kesepakatan dilakukan, sistem menjalankan pemangkasan otomatis (*trimming*) terhadap karakter non-alfanumerik di kedua ujung span NER agar perbedaan penyorotan tanda baca tepi (misalnya [KPAI...] vs. [KPAI]) diseragamkan terlebih dahulu, serta mengaudit pelanggaran aturan dasar (teks tanpa label, penggabungan NONE/UNANNOTATABLE dengan label lain, atau span kosong).

2.5.3 Adjudikasi Otomatis dan Manual

Pembentukan *gold standard dataset* dari hasil anotasi ketiga *annotator* dilakukan melalui prosedur adjudikasi dua tahap:

a) Adjudikasi Otomatis Berbasis Mayoritas (*majority voting*)

   Untuk Skema A (multilabel), setiap label dievaluasi secara independen dan ditetapkan sebagai label *gold* apabila dipilih oleh minimal dua dari tiga *annotator*. Untuk Skema B (NER), sebuah span akan masuk ke dalam daftar entitas *gold* apabila disorot secara identik oleh minimal dua *annotator* (setelah pemangkasan tanda baca tepi).

b) Adjudikasi Manual dan Koreksi Pedoman

   Sebuah teks dialihkan ke adjudikasi manual apabila:

   1) pada level dokumen tidak terdapat satu pun label yang mencapai suara mayoritas $\geq 2/3$ (misalnya ketiga *annotator* memilih label tunggal yang seluruhnya berbeda)
   2) label eksklusif (NONE/UNANNOTATABLE) memperoleh mayoritas bersamaan dengan label serangan lain
   3) pada level span NER terdapat rentang yang saling tumpang tindih pada ≥ 2 *annotator* tetapi memiliki batas token atau tipe entitas yang berbeda sehingga tidak mencapai mayoritas persis.

   Selain penyelesaian kasus konflik tersebut, diterapkan pula *guideline correction* untuk

menghapus span mayoritas yang terbukti melanggar daftar pengecualian pedoman (seperti penyorotan kata jabatan tanpa nama atau kata benda organisasi umum) dan memperbarui urutan tag BIO secara otomatis. Pada tahap akhir, seluruh rekaman yang memiliki keputusan akhir UNANNOTATABLE dikeluarkan dari berkas *gold dataset* sesuai aturan skema.

2.6 Metode Evaluasi Inter-Annotator Agreement (IAA)

Inter-annotator agreement (IAA) digunakan untuk mengukur sejauh mana annotator yang bekerja secara independen menghasilkan keputusan anotasi yang sama. Nilai IAA yang tinggi menunjukkan bahwa guideline cukup jelas dan label dapat diterapkan secara konsisten, sehingga gold dataset yang dihasilkan dapat dipercaya. Evaluasi IAA dilakukan secara terpisah untuk kedua tugas anotasi, yaitu klasifikasi multilabel jenis serangan verbal dan *Named Entity Recognition* (NER).

2.6.1 Desain overlap annotation

Seluruh 1.000 teks sampel utama dianotasi oleh tiga annotator secara mandiri menggunakan Prodigy, sehingga overlap annotation mencakup 100% data. Desain ini melebihi syarat minimal subset overlap dan menjamin bahwa semua label, termasuk label yang jarang, terwakili dalam perhitungan agreement. Sebelum anotasi utama, dilakukan uji coba (pilot) pada 50 teks di luar sampel utama dengan tiga annotator yang sama. Hasil IAA pilot dipakai untuk mengidentifikasi label yang rawan tertukar dan menjadi dasar revisi guideline (versi 1.0) sebelum anotasi utama dimulai.

Sebelum dihitung, data anotasi diperiksa kelengkapannya: setiap teks harus dikerjakan oleh ketiga annotator, tidak ada pasangan (teks, annotator) yang ganda, dan teks yang dianotasi harus identik dengan teks yang dikirim ke Prodigy. Export Prodigy digabung dengan kunci (id teks, annotator), dan bila satu kunci muncul di beberapa export, versi dengan timestamp terbaru yang dipakai. Anotasi yang melanggar aturan guideline (teks tanpa label, atau NONE digabung dengan label lain) tidak dibuang, tetapi tetap dihitung apa adanya agar IAA mencerminkan kondisi anotasi yang sebenarnya.

2.6.2 Agreement pada klasifikasi multilabel

Karena satu teks dapat memiliki lebih dari satu label, setiap label (*INSULTING, ACCUSING, MOCKING, PROVOKING, CURSING, NONE, dan UNANNOTATABLE*) diperlakukan sebagai keputusan biner tersendiri, dipilih atau tidak dipilih oleh annotator. Agreement kemudian dihitung per label.

Fleiss' kappa [6] digunakan karena setiap teks dinilai oleh lebih dari dua annotator. Untuk satu label, misalkan N adalah jumlah teks, n = 3 jumlah annotator per teks, dan n_ij jumlah annotator yang menempatkan teks i pada kategori j (j $\in$ {dipilih, tidak dipilih}).

Kesepakatan pada teks i adalah:

$$P_i = (\Sigma_j\, n_{ij}^2 - n) \,/\, (n(n-1))$$

Kesepakatan teramati dan kesepakatan yang diharapkan secara kebetulan adalah:

$$\bar{P} = \left(\frac{1}{N}\right) \Sigma_i\, P_i$$

$$p_j = \left(\frac{1}{N \cdot n}\right) \Sigma_i\, n_{ij}$$

$$\bar{P}_e = \Sigma_j\, p_j^2$$

sehingga

$$\kappa = \frac{\bar{P} - \bar{P}_e}{1 - \bar{P}_e}$$

Nilai κ = 1 berarti kesepakatan sempurna, κ = 0 berarti kesepakatan setara dengan kebetulan, dan κ < 0 berarti lebih buruk daripada kebetulan.

Selang kepercayaan bootstrap. Untuk menunjukkan ketidakpastian estimasi, terutama pada label yang jarang muncul, dihitung selang kepercayaan 95% dengan metode bootstrap persentil [7]. Teks diambil ulang secara acak dengan pengembalian sebanyak N teks, κ dihitung ulang, dan proses ini diulang 1.000 kali (seed = 0). Persentil ke-2,5 dan ke-97,5 dari 1.000 nilai κ dijadikan batas bawah dan batas atas selang kepercayaan.

Cohen's kappa per pasangan annotator. Untuk melihat apakah ada annotator yang menyimpang dari yang lain, dihitung Cohen's kappa [8] untuk setiap pasangan annotator (tiga pasangan) pada setiap label:

$$\kappa = \frac{p_o - p_e}{1 - p_e}$$

dengan p_o proporsi teks yang diputuskan sama oleh kedua annotator dan p_e = p_A·p_B + (1 − p_A)(1 − p_B), yaitu peluang kedua annotator sama secara kebetulan berdasarkan proporsi "dipilih" masing-masing (p_A dan p_B).

Ukuran ringkasan. Selain κ per label, dilaporkan tiga ukuran ringkasan:

1. rata-rata κ lima label serangan (*INSULTING, ACCUSING, MOCKING, PROVOKING, CURSING)* sebagai gambaran agreement keseluruhan;
2. κ "ada serangan vs tidak", yaitu κ untuk keputusan biner apakah teks memuat minimal satu label serangan;
3. persentase teks dengan himpunan label identik, yaitu teks yang ketiga annotatornya memilih kombinasi label yang persis sama.

2.6.3 Agreement pada NER

Agreement NER diukur di tingkat entitas menggunakan precision, recall, dan F1 antarannotator. Untuk setiap pasangan annotator A dan B, anotasi A diperlakukan sebagai prediksi dan anotasi B sebagai acuan [9]:

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1 = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall}$$

Karena peran A dan B dapat ditukar (precision A terhadap B sama dengan recall B terhadap A), F1 bersifat simetris dan dapat ditafsirkan sebagai ukuran agreement. Sebelum dibandingkan, tanda baca di awal dan akhir setiap span dipangkas (misalnya pendukungnya... menjadi pendukungnya), sehingga perbedaan yang hanya berupa ikut tersorotnya tanda baca tidak dihitung sebagai ketidaksepakatan. Dua kriteria kecocokan digunakan:

- F1 exact: span dianggap sama bila posisi awal, posisi akhir, dan tipe entitasnya persis sama.
- F1 overlap: span dianggap sama bila tipe entitasnya sama dan rentang karakternya beririsan. Ukuran ini menunjukkan seberapa besar ketidaksepakatan yang hanya berupa perbedaan batas span (misalnya [peserta] vs [peserta Audisi]), bukan perbedaan entitas.

F1 overlap dihitung sebagai 2·TP_overlap / (n_A + n_B), dengan n_A dan n_B jumlah entitas masing-masing annotator. Nilai F1 dilaporkan per pasangan annotator dan sebagai rata-rata ketiga pasangan.

2.6.4 Interpretasi dan validasi perhitungan

Nilai kappa ditafsirkan menggunakan skala [10]:

Tabel 2.2 Skala Interpretasi Nilai Kappa

Nilai κ	Interpretasi
< 0,00	buruk (poor)
0,00–0,20	sedikit (slight)
0,21–0,40	cukup (fair)
0,41–0,60	sedang (moderate)
0,61–0,80	substansial (substantial)
0,81–1,00	hampir sempurna (almost perfect)

Untuk label yang sangat jarang, nilai κ ditafsirkan bersama lebar selang kepercayaannya, karena sedikit perbedaan keputusan saja dapat mengubah κ secara besar.

2.7 Metode *Exploratory Data Analysis* (EDA) pada *Gold Dataset*

EDA dilakukan setelah gold dataset final tersedia (dataset/KelpNLP_dataset_annotation.jsonl, 999 teks setelah satu teks UNANNOTATABLE dikeluarkan). Tujuannya menjawab dua pertanyaan, pertama apakah distribusi label dan entitas cukup layak untuk pemodelan, dan kedua di mana potensi ketidakseimbangan (imbalance) berada. EDA dilakukan dengan Python (pandas, NumPy, Matplotlib) pada bagian kelima notebook. Sebelum analisis, integritas file gold diverifikasi dengan sidik SHA-256 agar EDA dipastikan berjalan pada versi gold yang sama dengan yang dilaporkan.

2.7.1 Persiapan data

Gold dataset diubah menjadi empat struktur data:

1. tabel teks: satu baris per teks, berisi utas berita, daftar label, panjang teks (karakter dan kata), jumlah token, dan jumlah entitas;
2. matriks label biner Y berukuran 999 × 6, dengan y_il = 1 bila teks i memiliki label l;
3. tabel entitas: satu baris per span, berisi tipe, teks, panjang karakter, dan panjang token;
4. deret tag BIO: satu baris per token.

Panjang entitas dalam token dihitung dari tag BIO (satu tag B- ditambah jumlah tag I- yang mengikutinya). Token yang dipakai adalah token Prodigy yang tersimpan di gold, karena unit inilah yang diberi tag BIO.

2.7.2 Analisis multilabel

Panjang teks diukur dalam karakter dan kata, lalu diringkas dengan statistik deskriptif (rata-rata, simpangan baku, kuartil, persentil ke-95, minimum, maksimum). Distribusinya divisualisasikan dengan histogram jumlah kata; ekor panjang di atas 150 kata digabung ke batang terakhir agar bentuk distribusi tetap terlihat. Setiap label dihitung jumlah dan persentase teks yang memilikinya (Σ_i y_il), lalu divisualisasikan dengan diagram batang horizontal.

Jumlah label per teks dihitung dari distribusi banyaknya label per teks serta dua ukuran standar multilabel [11]:

$$Label\ cardinality = \frac{1}{N}\ \Sigma_i\ |Y_i|$$

$$Label\ density = \frac{cardinality}{L}$$

dengan |Y_i| jumlah label teks i dan L = 6 jumlah label. Kombinasi label (labelset) yang

muncul juga dihitung frekuensinya.

Matriks co-occurrence dihitung sebagai C = $Y^T \cdot Y$, sehingga sel C_ab menyatakan jumlah teks yang memiliki label a dan b sekaligus; diagonalnya sama dengan jumlah teks per label. Matriks ini juga dinormalkan per baris menjadi peluang bersyarat P(b | a) = C_ab / C_aa, yaitu persentase teks berlabel a yang juga berlabel b. Keduanya divisualisasikan dengan heatmap.

Hubungan antarlabel diukur dengan koefisien korelasi Pearson pada variabel biner, yang setara dengan koefisien phi (φ):

$$\varphi_{ab} = \frac{n_{11} \cdot n_{00} - n_{10} \cdot n_{01}}{\sqrt{n_{1\bullet} \cdot n_{0\bullet} \cdot n_{\bullet 1} \cdot n_{\bullet 0}}}$$

Berbeda dengan co-occurrence, φ sudah memperhitungkan frekuensi masing-masing label: φ mendekati +1 bila dua label hampir selalu muncul bersama, mendekati 0 bila keduanya muncul bersama sesering yang diharapkan secara kebetulan, dan mendekati −1 bila keduanya hampir tidak pernah muncul bersama. Matriks φ divisualisasikan dengan heatmap divergen pada rentang tetap −1 sampai +1.

Ketidakseimbangan label diukur dengan metrik imbalance multilabel dari [12]:

$$\mathrm{IRLbl}(l) = \max_{l' \in L} \frac{\sum_i y_{il'}}{\sum_i y_{il}}$$

$$\mathrm{MeanIR} = \frac{1}{L} \sum_l \mathrm{IRLbl}(l)$$

$$\mathrm{CVIR} = \frac{\sigma(\mathrm{IRLbl})}{\mathrm{MeanIR}}$$

IRLbl bernilai 1 untuk label paling sering dan makin besar untuk label yang makin langka. Label dengan IRLbl > MeanIR dikategorikan sebagai label minoritas, sedangkan CVIR menunjukkan seberapa timpang perbedaan tingkat imbalance antarlabel. Karena setiap label nantinya dipelajari sebagai klasifikasi biner, dilaporkan juga rasio negatif:positif per label. Analisis ini dilengkapi tiga bagian:

- Jumlah kombinasi unik dan kombinasi langka (≤ 5 teks), serta ukuran SCUMBLE [13] yang mengukur seberapa sering label langka muncul bersama label umum dalam satu teks:

$$\mathrm{SCUMBLE}_i = 1 - \frac{\left(\prod_{l \in Y_i} \mathrm{IRLbl}(l)\right)^{\frac{1}{|Y_i|}}}{\frac{1}{|Y_i|} \sum_{l \in Y_i} \mathrm{IRLbl}(l)}$$

- SCUMBLE dataset adalah rata-rata SCUMBLE_i; nilai di atas 0,1 menandakan konkurensi tinggi antara label langka dan label umum, sehingga resampling sulit

memperbaiki imbalance.

- Hubungan imbalance dengan karakteristik teks, panjang teks (kata) dibandingkan per label dengan boxplot dan statistik kuartil, serta menurut banyaknya label per teks.
- Perbandingan dengan dan tanpa label minoritas, untuk memisahkan imbalance yang disebabkan satu label langka dari imbalance keseluruhan.

2.7.3 Analisis NER

Jumlah token Prodigy per teks diringkas dengan statistik deskriptif dan persentil ke-95 dan ke-99, lalu divisualisasikan dengan histogram. Sebagai pembanding, dihitung pula jumlah token bila tanda baca dipisahkan dari kata (pola \w+|[^\w\s]), untuk melihat pengaruh tokenisasi terhadap panjang input dan batas entitas.

Untuk setiap tipe entitas (GOV_ORG, NONGOV_ORG, PERSON, GROUP) dihitung jumlah entitas, jumlah teks yang memuatnya, persentase terhadap seluruh entitas, dan rata-rata kemunculan per teks yang memuatnya. Dihitung distribusi banyaknya entitas dalam satu teks (termasuk teks tanpa entitas), rata-rata, median, dan maksimum, baik secara keseluruhan maupun per tipe entitas.

Panjang entitas diukur dalam token dan karakter per tipe. Proporsi entitas 1, 2, 3, dan ≥ 4 token divisualisasikan dengan diagram batang bertumpuk 100%, karena entitas multi-token menentukan banyaknya contoh tag I- yang tersedia untuk model.

Teks entitas dinormalisasi ke huruf kecil, lalu dihitung delapan bentuk tersering per tipe. Keragaman entitas diukur dengan jumlah bentuk unik, persentase entitas yang tertutup oleh satu dan lima bentuk teratas, serta jumlah bentuk yang hanya muncul sekali. Variasi penulisan entitas utama (misalnya “KPAI” dan “Djarum”) juga diperiksa.

Distribusi tag BIO dihitung di tingkat token. Dominasi O diukur dengan persentase token berlabel O dan rasio O : token entitas (B + I). Imbalance antartipe entitas diukur dengan rasio jumlah token tipe terbanyak terhadap jumlah token setiap tipe, analog dengan IRLbl pada multilabel. Perbandingan jumlah tag B- dan I- per tipe juga dilaporkan untuk melihat ketersediaan contoh batas entitas multi-kata.

2.7.4 Prinsip visualisasi dan penarikan kesimpulan

Visualisasi disusun agar mudah dibaca dan tidak menyesatkan:

- palet warna yang sudah diuji aman untuk pembaca buta warna, dengan warna tetap untuk setiap tipe entitas di semua grafik.
- skala logaritmik untuk besaran yang rentangnya sangat lebar (IRLbl, jumlah tag BIO).
- nilai ditulis langsung pada batang grafik, dan identitas kategori tidak hanya

dibedakan dengan warna (juga dengan label, arsiran, atau keterangan sumbu).

Setiap analisis diikuti interpretasi singkat, dan EDA ditutup dengan kesimpulan yang menjawab kedua pertanyaan EDA serta implikasinya bagi pemodelan (strategi split data, penanganan imbalance, dan pemilihan metrik evaluasi). Karena sampel anotasi sengaja diperkaya teks berindikasi serangan, seluruh distribusi hasil EDA ditafsirkan sebagai karakteristik gold dataset, bukan sebagai proporsi pada seluruh komentar berita.

BAB III
HASIL DAN PEMBAHASAN

3.1 Hasil *Data Understanding*

3.1.1 Sumber dan Tujuan Awal Dataset

Dataset yang digunakan adalah dataset *Abusive-Language-Detection-on-Indonesian-Online-News-Comments* yang digunakan untuk penelitian oleh Desrul dan Romadhony [1] dalam konteks deteksi bahasa kasar (*abusive language*) pada komentar berita daring berbahasa Indonesia. Dataset ini berisi 3.184 komentar yang dikumpulkan dari beberapa portal berita dan forum daring, seperti Kompas dan Kaskus, pada topik-topik berita populer tahun 2019. Setiap komentar nantinya diberi label dalam bentuk *single label* yaitu *not abusive, abusive but not offensive, dan abusive and offensive*. Tujuan awal dataset ini adalah membangun sistem pendeteksi bahasa kasar secara otomatis sebagai klasifikasi teks, karena komentar yang mengandung pelecehan, hinaan, atau umpatan dapat berdampak negatif bagi pembaca, sedangkan penelitian serupa untuk bahasa Indonesia masih terbatas. Dalam penelitian tersebut, dataset digunakan untuk menguji beberapa algoritma klasifikasi, yaitu Naive Bayes, SVM, dan KNN, dengan seleksi fitur berbasis Mutual Information. Hasilnya, SVM menjadi klasifier terbaik dengan akurasi 90,19%.

3.1.2 Bahasa serta Domain Data

Dataset ini didominasi dengan Bahasa Indonesia dengan ragam tidak baku, yaitu bahasa percakapan khas kolom komentar daring. Hasil pemeriksaan menunjukkan bahwa sekitar 54,7% komentar memuat singkatan atau bentuk slang (misalnya *yg, dgn, tdk, klo, gak*), sekitar 17,7% memuat reduplikasi berangka (misalnya *anak2*), dan sebagian memuat pemanjangan huruf (*kaliiiii*), ekspresi tawa (*wkwk, haha*), serta kapitalisasi dan tanda baca berulang untuk penekanan emosi. Campur kode dengan bahasa Inggris dan bahasa daerah relatif kecil, masing-masing sekitar 2,5% dan kurang dari 7% komentar, sehingga bahasa utamanya tetap bahasa Indonesia informal. Selain itu, ditemukan kerusakan *encoding* hasil *crawling* pada sekitar 274 baris (*mojibake*) dan 106 baris (*escape sequence*), sehingga diperlukan pembersihan sebelum analisis lanjutan.

Dari sisi domain, dataset ini terdiri atas komentar pada berita-berita nasional daring tahun 2019 dengan topik yang beragam. Topik yang paling menonjol adalah polemik penghentian audisi PB Djarum akibat teguran KPAI, yang disebut pada sekitar 29,8% komentar, disusul isu politik dan kelembagaan nasional serta rencana akuisisi Indosat. Karena kumpulan komentar tercampur dari banyak utas berita, dataset ini bersifat multi-topik. Hal ini yang menjadi dasar pemilihan utas-utas berita polemik KPAI vs PB Djarum

sebagai domain penelitian pada subbab 2.3.1.

3.1.3 Jumlah Data dan Struktur Kolom

Dataset asli terdiri atas 3.184 baris dan 2 kolom. Kolom Kalimat bertipe teks berisi komentar mentah, dan kolom label bertipe bilangan bulat berisi label keabusifan. Tidak ditemukan nilai kosong pada kedua kolom. Dataset tidak memiliki kolom identitas, sumber portal, ID artikel, maupun penanda waktu, sehingga asal utas berita setiap komentar tidak dapat ditelusuri langsung dan baru dapat dikenali dari isi teksnya. Selain itu, repositori dataset menyertakan dua kamus pendukung normalisasi, yaitu "Acronym Words and Typos" (698 entri pasangan kata tidak baku dan kata baku) dan kumpulan singkatan dan kata dasar (sekitar 214 entri).

3.1.4 Label Asli

Label pada dataset asli sendiri masih bersifat *single label* yang terdiri dari 3 label: 1 (*not abusive*), 2 (*abusive but not offensive*), dan 3 (*abusive and offensive*). Label ini menilai tingkat keabusifan secara keseluruhan dan tidak menjelaskan jenis serangan verbalnya.

3.1.5 Distribusi Awal Data

Distribusi label pada awal data sangat timpang dimana kelas 1 berjumlah 2.789 komentar (87,6% dari jumlah data), kelas 2 berjumlah 110 (3,5% dari jumlah data), dan kelas 3 berjumlah 285 (9,0% dari jumlah data). Rasio kelas 1 terhadap kelas 2 sekitar 25:1, sehingga kelas 2 sangat langka. Panjang rata-rata komentar relatif seragam antarkelas (19,9 kata pada kelas 1, 19,5 pada kelas 2, dan 20,4 pada kelas 3), sehingga panjang teks bukan pembeda yang berarti. Secara keseluruhan, rata-rata panjang komentar adalah 19,9 kata dengan median 14 kata.

3.1.6 Masalah Kualitas Data yang Ditemukan

Pemeriksaan awal menemukan beberapa masalah kualitas seperti kerusakan *encoding* (*mojibake*) pada 274 baris dan *escape sequence* %uXXXX pada 106 baris. Kemudian ditemukan 15 baris duplikat persis (20 baris jika dibandingkan tanpa memperhatikan kapitalisasi dan spasi tepi), lalu 438 baris dengan spasi ganda, tab, atau baris baru. Pada dataset juga ditemukan sisa *markup* dan *escape* HTML/JSON pada 9 baris, tautan pada 3 baris, dan sebutan akun pada 2 baris, 5 baris tanpa huruf alfabet, 216 komentar sangat pendek (≤3 kata), termasuk 42 komentar satu kata, 30 komentar sangat panjang (>100 kata), dan variasi ejaan tidak baku yang tinggi, seperti singkatan, reduplikasi berangka, dan pemanjangan huruf. Kualitas label juga bermasalah karena distribusinya timpang dan tidak menunjukkan jenis serangan. Masalah-masalah ini ditangani pada tahap *cleaning* dan normalisasi.

3.1.7 Potensi Pengembangan Dataset Menjadi Permasalahan Multilabel dan NER

Komentar dalam dataset ini memuat target serangan yang jelas, seperti lembaga (KPAI, PB Djarum), tokoh, dan kelompok masyarakat, sehingga dapat dikembangkan menjadi dua tugas. Pertama, klasifikasi teks multilabel dimana satu komentar dapat memuat beberapa jenis serangan verbal sekaligus (*insulting, accusing, provoking, cursing, mocking*), yang tidak dapat diwakili label tunggal asli. Kedua, *Named Entity Recognition* (*NER*) untuk mengenali pihak yang diserang atau dibicarakan, yaitu organisasi pemerintah, organisasi non-pemerintah, individu, dan kelompok. Kedua tugas ini memperkaya dataset asli yang hanya mengukur tingkat keabusifan.

3.2 Hasil Fase Cleaning dan Normalisasi

3.2.1 Hasil Pembersihan *Noise*

Pada dataset asli baris yang ada adalah 3.184 baris, sedangkan proses pembersihan menghasilkan 3.157 baris text_clean. Sebanyak 27 baris (0,85%) dikeluarkan, yaitu 5 baris tanpa huruf alfabet dan 22 baris duplikat setelah pembersihan. Jumlah duplikat ini lebih besar daripada duplikat persis pada data mentah (15 baris) karena pembersihan menyeragamkan *encoding* dan spasi, sehingga teks yang semula tampak berbeda menjadi identik. Perbaikan karakter menjadi perubahan terbanyak: *mojibake* dipulihkan pada 348 baris, *escape sequence* %uXXXX didekode pada 106 baris, dan karakter pengganti *Unicode* dihapus pada 267 baris. Selain itu, 48 baris dibersihkan dari karakter tak terlihat, 9 baris dari sisa *markup* HTML/JSON, 2 baris diganti tautannya dengan [URL], dan 1 baris diganti sebutan akunnya dengan [USER]. Spasi diseragamkan pada 540 baris, dan spasi ditambahkan setelah tanda baca yang terjepit huruf pada 434 baris. Standardisasi NFC tidak mengubah baris apa pun (0 baris), sehingga teks sudah dalam bentuk kanonik. Teks asli tetap tersimpan pada text_raw, dan setiap baris bisa ditelusuri lewat ID yang dibuat yaitu "ANC-xxxx".

Tabel 3.1 Ringkasan Langkah Pembersihan

Tabel Ringkasan *Data Cleaning*			
Langkah	Tindakan	Baris Terdampak	Baris Tersisa
C1	Pemulihan *mojibake*	348	3.184
C2	Dekode *escape sequence*	106	3.184
C3	Penghapusan karakter hilang (U+FFFD)	267	3.184
C4	Penghapusan karakter tak terlihat	48	3.184
C5	Standardisasi Unicode NFC	0	3.184
C6	Pembersihan *markup* dan *escape*	9	3.184
C7	Penyensoran tautan ([URL])	2	3.184
C8	Penyensoran akun ([USER])	1	3.184
C9	Normalisasi spasi	540	3.184
C9b	Spasi setelah tanda baca	434	3.184
C10	Pembuangan baris tanpa huruf	5	3.179
C11	Pembuangan duplikat	22	3.157

3.2.2 Hasil Audit Kamus dan Normalisasi

Dua kamus bawaan (*Acronym Words and Typos* dengan 698 baris dan kumpulan singkatan dan kata dasar dengan 214 baris) berisi 810 kata unik setelah digabung, dengan 99 kata yang sama. Setelah diperiksa, sebanyak 131 kata dihapus karena pemetaannya kurang sesuai dengan konteks korpus, seperti “dpr”, “pt”, dan “pp”. Hasilnya, kamus final berisi 758 entri, yang terdiri dari 611 entri *Acronym Words and Typos*, 41 entri dari kumpulan singkatan, 27 perbaikan manual, dan 79 tambahan kosakata slang.

Proses normalisasi mengubah teks pada 2.371 dari 3.157 baris (75,1%). Perbandingan ini dilakukan terhadap teks yang sudah melalui proses *lowercase*. Jumlah kosakata unik juga berkurang dari 9.793 menjadi 8.984 token, atau turun 809 token (8,3%). Penurunan ini terjadi karena berbagai bentuk penulisan yang memiliki makna sama diseragamkan menjadi satu bentuk. Secara keseluruhan, terdapat 1.189 jenis pemetaan dengan 8.735 kali penggantian. Sebagian besar penggantian berasal dari kamus, diikuti oleh normalisasi kata ulang berangka, tawa, dan huruf berulang. Penggantian yang paling sering ditemukan adalah “yg” menjadi “yang” (1.199 kali), “aja“ menjadi “saja“ (471 kali), “ga“ menjadi “tidak“ (427 kali), “gak“ menjadi “tidak“ (337 kali), dan “anak2“ menjadi “anak-anak“ (259 kali).

Tabel 3.2 Ringkasan Jenis Normalisasi

Jenis	Pemetaan berbeda	Total penggantian
Kamus	706	7.587
Reduplikasi berangka	379	975
Tawa	46	108
Huruf berulang	54	61
Huruf berulang + kamus	4	4
Total	**1.189**	**8.735**

3.2.3 Hasil Seleksi Domain dan *Sampling*

Seleksi domain menandai 1.515 dari 3.157 komentar sebagai komentar domain KPAI vs PB Djarum, yang tersebar pada tiga utas berita: "KPAI Survei Ke Anak Yang Mana??" (178 komentar), "#bubarkanKPAI Trending di Twitter" (400), dan "PB Djarum Hentikan Audisi Bulutangkis" (937). Pada komentar domain, label asli kelas 1 berjumlah 1.355, kelas 2 berjumlah 30, dan kelas 3 berjumlah 130. Penyaringan *near-duplicate* mengeluarkan 6 komentar yang merupakan varian penulisan atau tagar dari teks yang sudah ada (misalnya variasi "#bubarkanKPAI" dan "Dimana KPAI"), sehingga populasi sampling menjadi 1.509 komentar (178, 397, dan 934 komentar pada utas 1, 2, dan 3). Dari populasi ini diambil 1.050 komentar: sampel pilot 50 komentar (25 strata prioritas, 25 strata umum) dan sampel utama 1.000 komentar (476 prioritas, 524 umum). Seluruh 160 komentar domain yang berlabel asli abusif (30 kelas 2 dan 130 kelas 3) masuk ke sampel, sehingga tidak ada contoh abusif yang terlewat. Komposisi sampel pada ketiga utas proporsional terhadap ukuran utas (sampel utama 118, 263, dan 619 komentar), dan label asli sampel menjadi 890 kelas 1, 30 kelas 2, dan 130 kelas 3.

Tabel 3.3 Komposisi Sampel

Bagian	Prioritas	Umum	Total	Utas 1	Utas 2	Utas 3
Pilot	25	25	50	5	14	31
Utama	476	524	1.000	118	263	619

3.3 Hasil Anotasi, *Inter Annotator Agreement* dan Adjudikasi

3.3.1 Hasil Uji Coba Pilot dan Revisi Pedoman

Pertama kali, dilakukan uji coba pada 50 teks pilot oleh tiga annotator yang

menghasilkan Fleiss' kappa yang bervariasi antarlabel: INSULTING 0,85, PROVOKING 0,78, ACCUSING 0,67, MOCKING 0,59, dan NONE 0,43, dengan rata-rata empat label serangan yang muncul sebesar 0,72. CURSING dan UNANNOTATABLE tidak muncul pada sampel pilot. Himpunan label ketiga annotator identik hanya pada 25 dari 50 teks, dan F1 exact NER sebesar 0,85.

Ketidaksepakatan terbesar terjadi pada MOCKING, yang dimana satu annotator memilih label ini pada 21 teks, sedangkan dua lainnya pada 11 dan 14 teks. Rendahnya κ NONE menunjukkan batas antara kritik biasa dan tuduhan (ACCUSING) belum jelas. Pada NER, perbedaan terutama muncul karena kata umum ikut disorot (sponsor, bangsa, negara, pejabat). Temuan ini menjadi dasar revisi pedoman versi 1.0, antara lain penambahan lima pertanyaan uji yang memisahkan isi dan cara serangan, penulisan ulang definisi ACCUSING, aturan komentar berbentuk pertanyaan, aturan GROUP sebagai kelas terbuka, dan aturan batas NER nomor 9-12.

3.3.2 Kelengkapan Anotasi Utama

Anotasi utama menghasilkan 3.000 rekaman data (1.000 teks × 3 annotator: Rhiquel, SamuelViva, dan edwardchristi4n) dan setiap teks dikerjakan oleh ketiga annotator tersebut. Selama anotasi berjalan, salah satu export Prodigy pada tanggal 3 November 2026 hanya memuat sebagian data yakni 419 rekaman dari 108 teks yang sudah dianotasi tidak ikut terekspor. Seluruh rekaman tersebut berhasil dipulihkan secara identik melalui prosedur penggabungan berbasis kunci (id, annotator) dan timestamp yang dijelaskan pada subbab 2.5.2, sehingga tidak ada anotasi yang hilang.

Pemeriksaan aturan dasar menemukan 5 pelanggaran dari 3.000 rekaman yang dimana empat teks tanpa label (ANC-1244 dan ANC-2427 oleh satu annotator; ANC-2273 dan ANC-2298 oleh annotator lain) dan satu teks dengan NONE yang digabung dengan MOCKING (ANC-1271). Tidak ditemukan span kosong. Pelanggaran tersebut tetap dihitung apa adanya dalam IAA dan diselesaikan pada tahap adjudikasi.

3.3.3 Hasil IAA Klasifikasi Multilabel

Tabel 3.4 Fleiss' Kappa per Label (1.000 teks × 3 annotator)

Label	Fleiss' κ	CI 95% (bootstrap)	Interpretasi
PROVOKING	0,950	0,93–0,97	hampir sempurna
INSULTING	0,886	0,86–0,91	hampir sempurna
ACCUSING	0,833	0,80–0,86	hampir sempurna
NONE	0,807	0,77–0,84	hampir sempurna
MOCKING	0,795	0,76–0,83	substansial
CURSING	0,737	0,43–0,91	substansial
UNANNOTATABLE	0,750	0,00–1,00	substansial
Rata-rata 5 label serangan	**0,840**	–	**hampir sempurna**

Rata-rata Fleiss' kappa lima label serangan sebesar 0,840 termasuk kategori hampir sempurna. Kappa untuk keputusan "ada serangan vs tidak ada serangan" sebesar 0,812, dan ketiga annotator memilih himpunan label yang persis sama pada 716 dari 1.000 teks (72%). PROVOKING paling konsisten karena umumnya ditandai kata kerja tindakan yang eksplisit (bubarkan, tutup, mundur). MOCKING memiliki κ terendah di antara label serangan yang sering muncul, yang wajar karena ironi, sarkasme, dan pujian palsu paling bergantung pada tafsir pembaca. CURSING dan UNANNOTATABLE sangat jarang (masing-masing hanya muncul di beberapa teks), sehingga selang kepercayaannya sangat lebar dan nilai κ keduanya tidak dijadikan patokan utama.

Cohen's kappa rata-rata lima label per pasangan annotator adalah 0,819 (Rhiquel–SamuelViva), 0,837 (Rhiquel–edwardchristi4n), dan 0,867 (SamuelViva–edwardchristi4n). Ketiga pasangan berada pada kategori hampir sempurna, sehingga tidak ada annotator yang menyimpang secara sistematis dari yang lain. Dibandingkan hasil pilot (rata-rata 0,72; himpunan identik 50%), kesepakatan meningkat setelah revisi pedoman, terutama pada ACCUSING, MOCKING, dan NONE.

3.3.4 Hasil IAA NER

Rata-rata skor F1 antar annotator mencapai 0,926 (exact) dan 0,942 (overlap), naik dari 0,85 pada pilot. Selisih kecil antara F1 *exact* dan *overlap* menunjukkan bahwa sebagian ketidaksepakatan hanya berupa perbedaan batas span. Contohnya [peserta] vs [peserta Audisi], atau [anak] vs [anak muda], di mana annotator sepakat bahwa entitas ada dan sepakat tipenya, tetapi berbeda dalam menentukan kata yang ikut disorot.

3.3.5 Contoh Disagreement

Tabel 3.5 Contoh Disagreement

ID	Jenis	Ketidaksepakatan	Keputusan dan alasan
ANC-2850	Label	Tidak ada label mayoritas	NONE: hiperbola pembanding (“negara lain udah ke bulan”) bukan ejekan terhadap target
ANC-1271	Label	Satu annotator menggabungkan NONE + MOCKING	NONE: keluhan kondisi tanpa target dan tanpa cap, tuduhan, atau ejekan
ANC-1124	NER	[peserta] vs [peserta Audisi]	[peserta] GROUP (aturan kata inti)
ANC-1152	NER	Batas dan tipe berbeda	[Komisi Nasional Perlindungan Anak] NONGOV_ORG (Komnas PA adalah lembaga swadaya, bukan lembaga negara)

3.3.6 Hasil Adjudikasi

Tabel 3.6 Status Keputusan Adjudikasi Label dan NER

Status	Label	NER
Sepakat 3/3	716	731
Mayoritas 2/3	279	256
Manual	5	13

Sebanyak 18 teks diputuskan secara manual termasuk 5 karena label dan 13 karena batas atau tipe span NER. Sisanya ditetapkan otomatis melalui *majority voting*. Seluruh perubahan dari gold otomatis ke gold final tercatat di KelpNLP_log_keputusan.csv yang isinya mencakup 5 perubahan label manual, 22 span ditambahkan, 2 span dihapus secara manual, dan 26 span dihapus melalui koreksi pedoman. Koreksi pedoman menghapus span mayoritas yang bertentangan dengan pedoman NER, yaitu jabatan tanpa nama (pejabat, menpora, komisioner), kata umum organisasi (lsm, ormas), julukan (minions, Daddies), dan tokoh fiksi (sizuka).

Setelah aturan pedoman dicocokkan dengan gold, ditemukan pula beberapa span yang lolos voting tetapi tidak sesuai pedoman, dan span tersebut diperbaiki. Contohnya [PB Baygon] dan [PB Hit] serta [Taliban] ditambahkan sebagai NONGOV_ORG, “pendukung” ditambahkan sebagai GROUP, [generasi muda] dipangkas menjadi [generasi], dan [KOMNAS HAM..11] dipotong menjadi [KOMNAS HAM]. Untuk BUMN, tim memutuskan mengikuti pilihan ketiga annotator sehingga [Pertamina] tetap GOV_ORG.

Satu teks berlabel UNANNOTATABLE (ANC-2866, “Jangkrikkkkkk bossssss.....”, disepakati 3/3) dikeluarkan sesuai aturan skema. Gold dataset final berisi 999 teks dengan 2.205 entitas, dan seluruhnya lolos 17 uji validasi otomatis: kecocokan dengan text_clean, aturan label eksklusif, keabsahan dan urutan span, serta konsistensi tag BIO dengan span.

3.3.7 Perubahan Pedoman

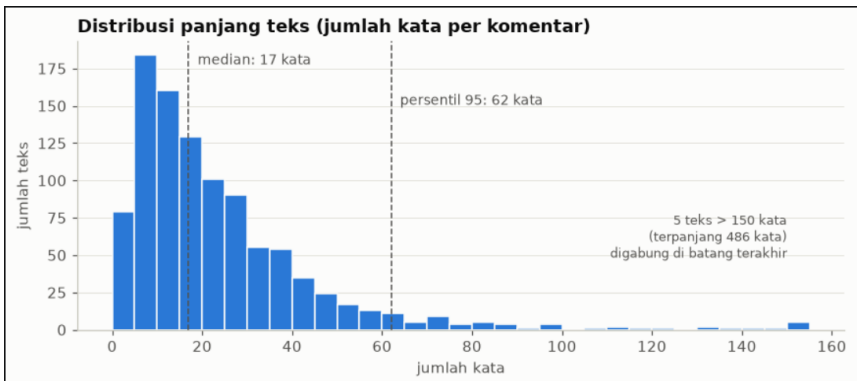
Pedoman anotasi mengalami tiga kali pembaruan: versi 1.0 setelah pilot (lima pertanyaan uji isi vs cara, penulisan ulang ACCUSING, aturan GROUP dan batas NER), versi 1.1 dari sesi kalibrasi selama anotasi utama (penanda label tambahan serta aturan jabatan, merek, dan julukan pada NER), dan versi 1.2 setelah adjudikasi (aturan adjudikasi, BUMN sebagai GOV_ORG, dan pengeluaran teks UNANNOTATABLE). Rincian 44 butir perubahan beserta contoh ID dicatat pada **guideline/log_perubahan_guideline.txt**.

3.4 Hasil *Exploratory Data Analysis* (EDA)

3.4.1 Hasil EDA *Multilabel*

Hasil Exploratory data analysis pada bagian multi label mencakup 6 bagian yang direpresentasikan sebagai berikut:

a. Jumlah dan panjang teks



Gambar 3.1 Distribusi Panjang Teks

Gold dataset sendiri berisi 999 teks. Dapat dilihat pada Gambar 3.1 teks dalam dataset sendiri memiliki panjang median 17 kata (109 karakter) dan rata-rata 23,7 kata. Sebanyak 95% teks tidak lebih dari 62 kata, tetapi distribusinya memiliki ekor panjang: 15 teks lebih dari 100 kata, dan teks terpanjang mencapai 486 kata. Ada 47 teks sangat pendek (≤ 3 kata) yang sengaja dipertahankan karena sering memuat serangan yang jelas.

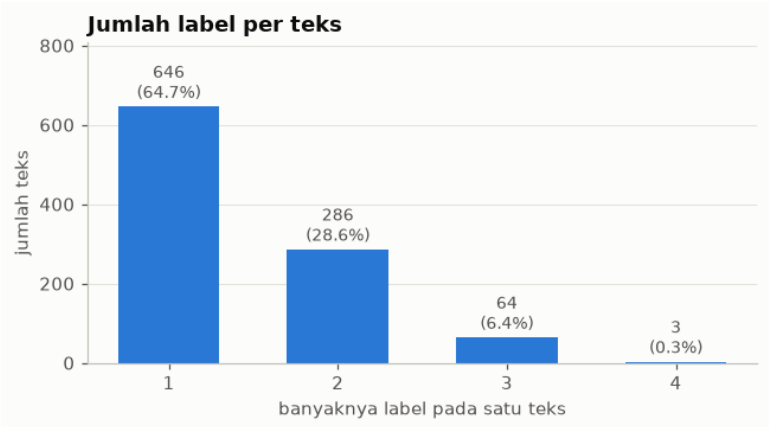
b. Distribusi Label



Gambar 3.2 Distribusi Label

Distribusi setiap label dapat dilihat pada Gambar 3.2, label terbanyak adalah label ACCUSING dengan total 370 teks, INSULTING 364 teks, dan MOCKING 332 teks. Kemudian disusul dengan NONE 181 teks dan PROVOKING 168 teks. CURSING hanya muncul pada 7 teks.

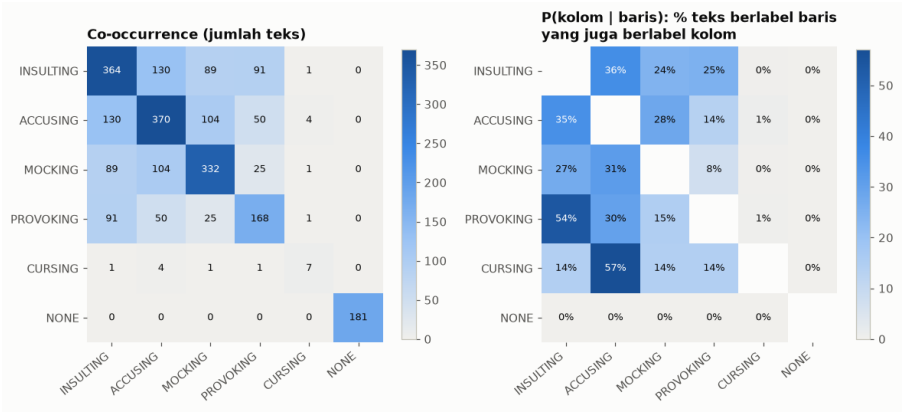
c. Jumlah label per teks



Gambar 3.3 Jumlah Label per Teks

Dapat dilihat pada Gambar 3.3, sebanyak 646 teks (64,7%) memiliki satu label, 286 (28,6%) dua label, 64 (6,4%) tiga label, dan 3 (0,3%) empat label. Label cardinality sebesar 1,42 dan label density 0,237, dengan 35,3% teks multilabel. Terdapat 21 kombinasi label unik. Kombinasi tersering adalah NONE (181), MOCKING (156), ACCUSING (145), INSULTING (119), dan INSULTING + ACCUSING (74).

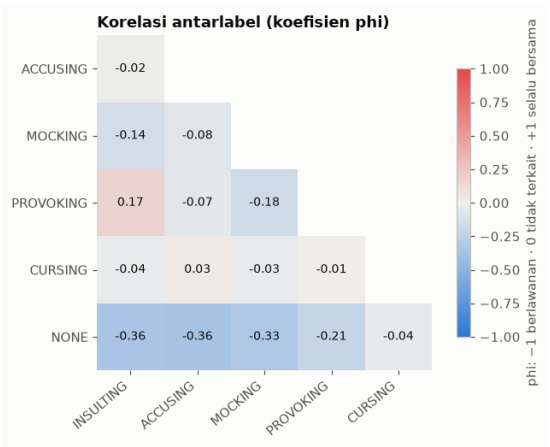
d. *Co-occurrence*



Gambar 3.4 Co-occurrence Label

Pasangan yang paling sering muncul bersama adalah INSULTING–ACCUSING (130 teks), ACCUSING–MOCKING (104), INSULTING–PROVOKING (91), dan INSULTING–MOCKING (89). Sebanyak 54% teks PROVOKING juga berlabel INSULTING, dan 4 dari 7 teks CURSING juga berlabel ACCUSING. NONE tidak pernah muncul bersama label lain, sesuai aturan label eksklusif, seperti yang terlihat pada Gambar 3.4.

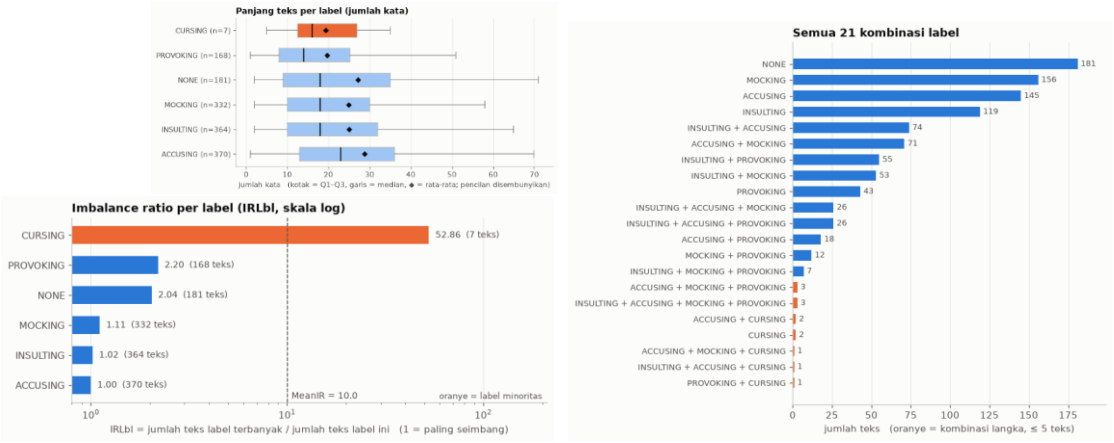
e. Korelasi antar label



Gambar 3.5 Korelasi Antar Label

Dapat dilihat pada Gambar 3.5, seluruh korelasi antarlabel serangan lemah ($|\varphi| \leq 0{,}18$). Korelasi positif terkuat adalah INSULTING–PROVOKING (+0,17), sedangkan MOCKING cenderung terpisah dari PROVOKING (−0,18) dan INSULTING (−0,14). INSULTING dan ACCUSING muncul bersama di 130 teks, tetapi φ-nya ≈ −0,02, artinya keduanya muncul bersama hanya sesering yang diharapkan secara kebetulan karena sama-sama sering. NONE berkorelasi negatif dengan semua label (hingga −0,36). Hasil ini menunjukkan tidak ada label yang redundan; setiap label membawa informasi tersendiri.

f. *Imbalance Ratio*



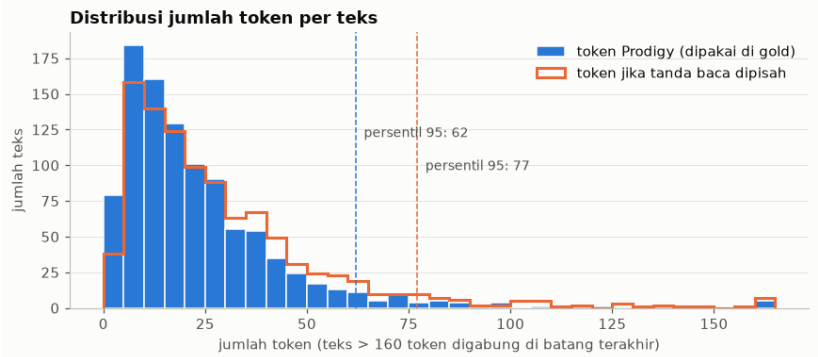
Gambar 3.6 Panjang Teks per Label, Imbalance Ratio per Label, dan Kombinasi Label

Secara keseluruhan rasio label terbanyak terhadap tersedikit sebesar 52,9, dengan MeanIR 10,04 dan CVIR 1,91 (Gambar 3.6). Namun ketimpangan ini hampir seluruhnya disebabkan CURSING (IRLbl 52,86; rasio negatif:positif 142:1), satu-satunya label minoritas (IRLbl > MeanIR). Tanpa CURSING, rasio terbanyak/tersedikit hanya 2,2 dan MeanIR 1,48. Dari 21 kombinasi label, 7 tergolong langka (≤ 5 teks; total 13 teks), dan 5 di antaranya melibatkan CURSING. SCUMBLE dataset sebesar 0,012, jauh di bawah ambang 0,1 [13], tetapi SCUMBLE teks CURSING mencapai 0,52 karena label ini hampir selalu menempel pada label umum. Dari sisi panjang teks, ACCUSING memiliki teks terpanjang (median 23 kata) dan PROVOKING terpendek (median 14 kata). Panjang teks juga meningkat seiring jumlah label: median 15 kata untuk satu label hingga 63 kata untuk empat label.

3.4.2 Hasil EDA NER

Hasil EDA NER meliputi 6 fase yakni sebagai berikut:

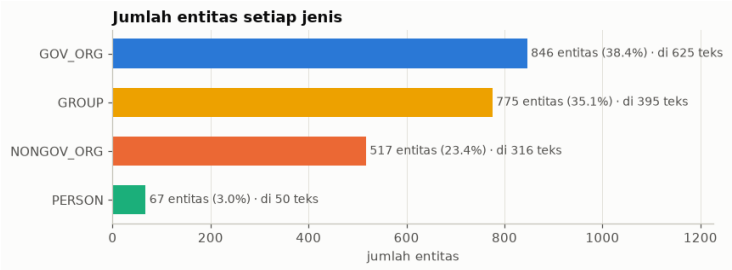
a. Distribusi Jumlah token per teks



Gambar 3.7 Distribusi Jumlah Token per Teks

Token Prodigy identik dengan pemisahan berbasis spasi pada seluruh 999 teks, dengan median 17 token, persentil ke-95 sebesar 62 token, dan persentil ke-99 sebesar 122 token (Gambar 3.7). Akibat tokenisasi ini, tanda baca menempel pada kata di 814 teks (mis. token KPAI...!!!). Bila tanda baca dipisah, jumlah token naik sekitar 24% (median 22, persentil ke-95 sebesar 77).

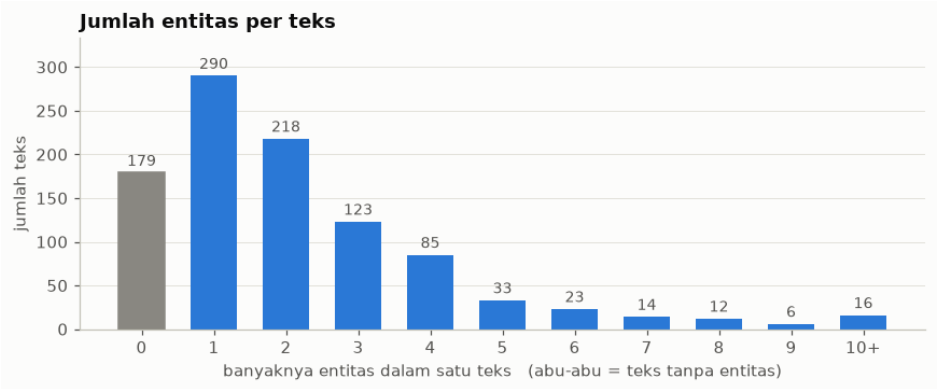
b. Entitas per jenis



Gambar 3.8 Jumlah Entitas per Jenis

Dari 2.205 entitas, GOV_ORG berjumlah 846 (38,4%; muncul di 62,6% teks), GROUP 775 (35,1%), NONGOV_ORG 517 (23,4%), dan PERSON hanya 67 (3,0%; di 50 teks). Rasio jenis terbanyak/tersedikit sebesar 12,6 (Gambar 3.8).

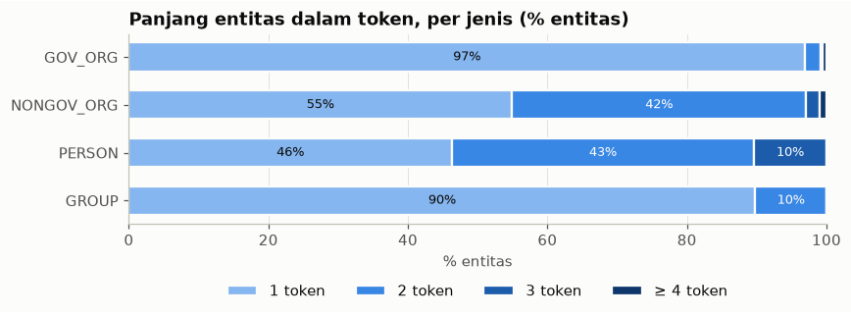
c. Entitas per teks



Gambar 3.9 Jumlah Entitas per Teks

Rata-rata 2,21 entitas per teks (median 2 dan maksimum 30; Gambar 3.9). Sebanyak 179 teks (17,9%) tidak memuat entitas; teks seperti ini biasanya hanya menyebut sasaran secara tersirat atau dengan kata ganti.

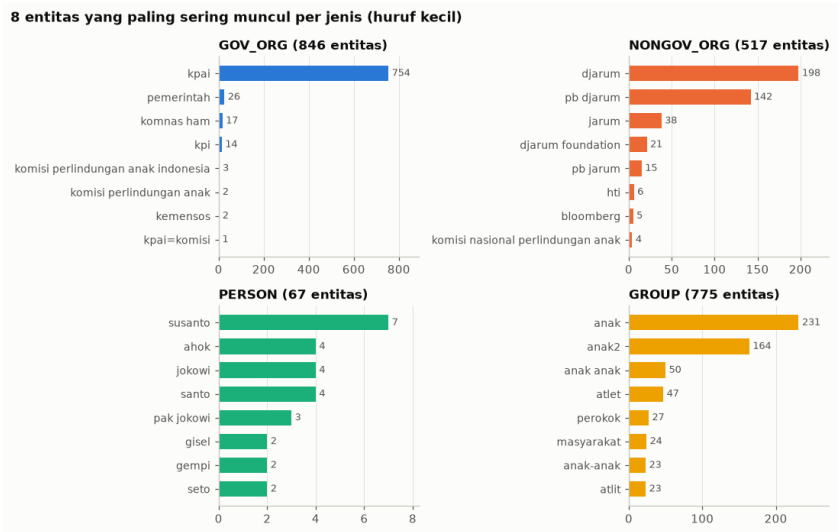
d. Panjang entitas



Gambar 3.10 Panjang Entitas per Jenis

Sebanyak 83% entitas terdiri atas satu token (Gambar 3.10). GOV_ORG hampir selalu satu token (97%), sedangkan NONGOV_ORG (45%) dan PERSON (54%) sering terdiri atas lebih dari satu token (mis. “PB Djarum”, “Pak Jokowi”). Entitas terpanjang terdiri atas 4 token.

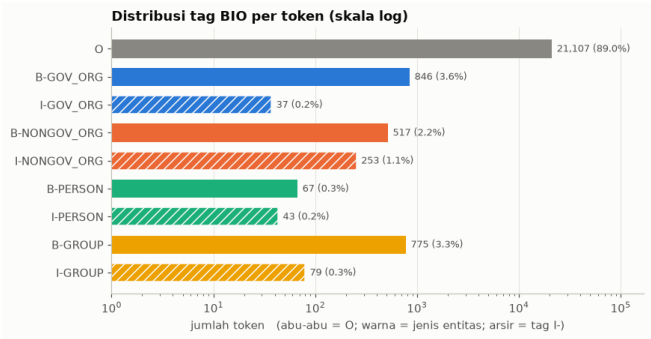
e. Entitas dengan Frekuensi Kemunculan Tertinggi



Gambar 3.11 Entitas dengan Frekuensi Kemunculan Tertinggi per Jenis

GOV_ORG sangat homogen dimana 89% berupa “kpai” dalam berbagai penulisan (Gambar 3.11). NONGOV_ORG didominasi varian Djarum, dan GROUP didominasi varian “anak”. PERSON paling beragam, dengan 43 bentuk dari 67 entitas, 31 di antaranya hanya muncul sekali. Variasi penulisan juga tinggi, misalnya “KPAI” muncul dalam 12 bentuk dan “Djarum” dalam 32 bentuk.

f. Dominasi O dan *Imbalance Entity*



Gambar 3.12 Distribusi Tag BIO per Token

Sebanyak 89,0% token berlabel O, dengan rasio O : token entitas sebesar 8,1 : 1 (Gambar 3.12). GOV_ORG, GROUP, dan NONGOV_ORG relatif seimbang (770–883 token entitas). PERSON merupakan minoritas (110 token; imbalance ratio 8,0), dan tag I- sangat jarang (412 token dibanding 2.205 tag B-), terutama I-GOV_ORG (37 token) dan I-PERSON (43 token).

3.4.3 Kesimpulan hasil EDA

Distribusi label layak untuk pemodelan pada lima dari enam label multilabel dan pada tiga dari empat tipe entitas. Potensi imbalance terletak pada:

1. CURSING (7 teks), yang terlalu sedikit untuk dilatih dan dievaluasi sebagai label tersendiri.
2. PERSON dan tag I- pada NER.
3. Dominasi token O, yang membuat akurasi per token tidak bermakna.

Implikasi untuk tahap UAS:

- Pembagian data: *iterative stratification*, dengan teks hampir-duplikat ditempatkan di split yang sama.
- Model multilabel: satu keluaran biner per label (binary relevance), dengan bobot kelas dan threshold per label; NONE dapat diturunkan dari tidak terdeteksinya kelima label serangan.
- Metrik: micro/macro-F1 dan F1 per label untuk multilabel, serta F1 tingkat entitas untuk NER.
- Keterangan CURSING: dilaporkan terpisah atau dikeluarkan dari rata-rata metrik utama.

Karena sampel sengaja diperkaya teks berindikasi serangan (strata prioritas 47,6%), distribusi ini menggambarkan gold dataset, bukan proporsi pada seluruh komentar berita.

BAB IV
KESIMPULAN

Penelitian ini berhasil mereformulasi dataset *Abusive Language Detection on Indonesian Online News Comments* dari pelabelan kelas tunggal menjadi gold standard dataset untuk dua permasalahan NLP, yaitu *Multilabel Text Classification* jenis serangan verbal dan *Named Entity Recognition* (NER) pihak yang disebut, pada domain polemik KPAI vs PB Djarum. Melalui pembersihan *noise* dan normalisasi terkontrol (3.184 menjadi 3.157 baris), seleksi domain (1.515 komentar), dan stratified sampling, sebanyak 1.000 teks dianotasi secara mandiri oleh tiga annotator dengan overlap 100%. Hasilnya, kesepakatan antar-annotator tergolong hampir sempurna (rata-rata Fleiss' κ lima label serangan 0,840 serta F1 NER 0,926 exact dan 0,942 overlap), dan seluruh konflik diselesaikan melalui *majority voting* dan adjudikasi manual pada 18 teks. Gold dataset final berisi 999 teks dengan 2.205 entitas yang lolos seluruh uji validasi. Hasil EDA menunjukkan bahwa distribusi label layak untuk pemodelan pada lima dari enam label multilabel (ACCUSING, INSULTING, MOCKING, NONE, dan PROVOKING) dan tiga dari empat tipe entitas (GOV_ORG, GROUP, dan NONGOV_ORG). Potensi *imbalance* terletak pada label CURSING yang hanya muncul pada 7 teks (IRLbl 52,86), entitas PERSON (67 entitas) beserta tag I-, serta dominasi token O sebesar 89%. Temuan ini menjadi dasar bagi tahap pemodelan berikutnya, yaitu pembagian data dengan iterative stratification, penggunaan bobot kelas dan threshold per label, serta evaluasi menggunakan micro/macro-F1 dan F1 tingkat entitas, dengan CURSING dilaporkan secara terpisah.

DAFTAR PUSTAKA

[1] D. R. Kiasati Desrul and A. Romadhony, "Abusive Language Detection on Indonesian Online News Comments," in *2019 International Seminar on Research of Information Technology and Intelligent Systems (ISRITI)*, IEEE, Dec. 2019, pp. 320–325. doi: 10.1109/ISRITI48646.2019.9034620.

[2] S. Cahyawijaya *et al.*, "NusaCrowd: Open Source Initiative for Indonesian NLP," in *Findings of the Association for Computational Linguistics: ACL 2023*, 2023. [Online]. Available: https://indonlp.github.io/

[3] M. O. Ibrohim and I. Budi, "Multi-label Hate Speech and Abusive Language Detection in Indonesian Twitter," in *Proceedings of the Third Workshop on Abusive Language Online*, Stroudsburg, PA, USA: Association for Computational Linguistics, 2019, pp. 46–57. doi: 10.18653/v1/W19-3506.

[4] B. Plank, "The 'Problem' of Human Label Variation: On Ground Truth in Data, Modeling and Evaluation," in *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing, EMNLP 2022*, 2022, pp. 10671–10682. doi: 10.18653/v1/2022.emnlp-main.731.

[5] I. Honnibal, Matthew, Montani, "Prodigy: An annotation tool for AI, Machine Learning & NLP," Explosion. Accessed: Nov. 11, 2026. [Online]. Available: https://prodi.gy/industries/research-education

[6] J. L. Fleiss, "Measuring nominal scale agreement among many raters.," *Psychol. Bull.*, vol. 76, no. 5, pp. 378–382, Nov. 1971, doi: 10.1037/h0031619.

[7] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. Chapman and Hall/CRC, 1994. doi: 10.1201/9780429246593.

[8] J. Cohen, "A Coefficient of Agreement for Nominal Scales," *Educ. Psychol. Meas.*, vol. 20, no. 1, pp. 37–46, Apr. 1960, doi: 10.1177/001316446002000104.

[9] G. Hripcsak and A. S. Rothschild, "Agreement, the F-measure, and reliability in information retrieval," *J. Am. Med. Informatics Assoc.*, vol. 12, no. 3, pp. 296–298, 2005, doi: 10.1197/jamia.M1733.

[10] J. R. Landis and G. G. Koch, "The Measurement of Observer Agreement for Categorical Data," *Biometrics*, vol. 33, no. 1, pp. 159–174, Mar. 1977, doi: 10.2307/2529310.

[11] G. Tsoumakas and I. Katakis, "Multi-Label Classification: An Overview," *Int. J. Data Warehous. Min.*, vol. 3, no. 3, pp. 1–13, Jul. 2007, doi: 10.4018/jdwm.2007070101.

[12] F. Charte, A. J. Rivera, M. J. del Jesus, and F. Herrera, "Addressing imbalance in multilabel classification: Measures and random resampling algorithms," *Neurocomputing*, vol. 163, pp.

3–16, 2015, doi: 10.1016/j.neucom.2014.08.091.

[13] F. Charte, A. J. Rivera, M. J. del Jesus, and F. Herrera, “Dealing with difficult minority labels in imbalanced mutilabel data sets,” *Neurocomputing*, vol. 326–327, pp. 39–53, Jan. 2019, doi: 10.1016/j.neucom.2016.08.158.